

Juin 2026

Rapport académique

Adaptive Gradient Methods

Étude des méthodes de gradient adaptatif en NLP

Comparaison de 5 optimiseurs pour le fine-tuning de DistilBERT sur IMDB

Ghazli Mohamed Amine

Hamroudi Ayoub

Mousslim Jad

Boulatar Mouad

Master Data Science, Big Data & IA

Module : Algorithmes d'Optimisation

Supervisé par : Prof. Amine Amine Tobi Tacos

Plan

- ▶ Contexte
- ▶ Optimiseurs
- ▶ Méthodologie
- ▶ Résultats
- ▶ Analyses
- ▶ Discussion
- ▶ Conclusion

- ▶ Les Transformers dominent les tâches modernes de NLP.
- ▶ Le fine-tuning reste sensible au choix de l'optimiseur.
- ▶ Les gradients peuvent être bruités et mal conditionnés.
- ▶ Le learning rate est un hyperparamètre critique.

Comparer les optimiseurs selon quatre axes

- ▶ Convergence
- ▶ Stabilité
- ▶ Mémoire GPU
- ▶ Généralisation

Optimiseur	Type	Année
SGD + Momentum	Non adaptatif	
AdamW	Adaptatif	2017
AdaFactor	Adaptatif	2018
LAMB	Adaptatif	2019
Lion	Adaptatif	2023

Optimiseur	Mécanisme principal
SGD + Momentum	Lissage de la direction par inertie.
AdamW	Moments adaptatifs et weight decay découplé.
AdaFactor	Adaptation avec mémoire réduite.
LAMB	Adaptation couche par couche pour grands batchs.
Lion	Mise à jour compacte fondée sur le signe.

DistilBERT

- ▶ 66M paramètres
- ▶ 6 couches

IMDB

- ▶ 8000 train
- ▶ 2000 val
- ▶ 2000 test
- ▶ 50/50


Protocole expérimental

Paramètre	Valeur
Seed	42
Epochs	3
Batch	16
LR	2e-5
Weight decay	0.01
Max length	256
Warmup	10%
AMP	Activé

Résultats globaux





Optimiseur	Accuracy	F1	GPU	Temps
AdaFactor	89.65%	89.72%	1204 MB	263.5s
AdamW	89.50%	89.53%	1724 MB	250.6s
Lion	85.65%	85.99%	1468 MB	243.8s
LAMB	81.70%	81.52%	1719 MB	273.3s
SGD	53.35%	53.79%	1458 MB	235.6s

Classement : AdaFactor, AdamW, Lion, LAMB, SGD.





Convergence

- ▶ AdamW & AdaFactor : rapide
- ▶ SGD : instable
- ▶ Lion : léger overfit
- ▶ LAMB : lent






Sensibilité au LR




Batch size

- ▶ AdaFactor stable
- ▶ LAMB & SGD chutent



Discussion

- ▶ AdaFactor = meilleur compromis
- ▶ SGD échoue : gradients mal conditionnés
- ▶ AdamW = baseline stable



Conclusion

- ▶ AdaFactor recommandé pour un contexte low GPU.
- ▶ AdamW reste un choix sûr.
- ▶ Lion est sensible au LR.
- ▶ Perspective : MiniLM.

Merci

Questions

GitHub

<https://github.com/BOULATARM/projet16-adaptive-gradient-methods-nlp>